Mondragon Unibertsitatea
Enpresagintza Fakultatea

Propiedades de las Series Temporales Estructurales

Apuntes completos

Elaborados a partir de las diapositivas «Series Temporales Estructurales (repaso)»
Profesora: Irantzu Calvo Santamaria · icalvo@mondragon.edu

Índice

1 Componentes de las series temporales 3
Repaso . . . 3
¿Qué es una serie temporal? . . . 3
Componentes de las series temporales . . . 3
1.1 Tendencia . . . 4
Modelos de tendencia . . . 4
Eliminación de la tendencia . . . 5
1.2 Estacionalidad . . . 6
Tipos de estacionalidad . . . 6
Causas de la estacionalidad . . . 7
Componente cíclica . . . 7
Comprobación de la estacionalidad . . . 7
Transformada de Fourier . . . 8
Eliminación de la estacionalidad . . . 9
1.3 Residuo . . . 9
Ruido o residuo . . . 9
Puntos de impacto . . . 10
1.4 Autocorrelación . . . 10
Autocorrelación . . . 10
Función de autocorrelación (ACF) . . . 11
ACF según el tipo de serie . . . 12
Autocorrelación parcial (PACF) . . . 14
Selección del modelo . . . 15
1.5 Estacionariedad . . . 16
Definición de estacionariedad . . . 16
Matices en la definición de estacionariedad . . . 17
Conversión de una serie en estacionaria . . . 18
Comprobar estacionariedad . . . 18
Unit roots / raíces unitarias . . . 19
Unit Root Tests . . . 19
Heterocedasticidad . . . 20
Test de heterocedasticidad . . . 20
Test de Engle . . . 21

2 Series temporales estructurales 22
Series temporales estructurales y su descomposición . . . 22
¿Qué es una serie temporal estructural? . . . 22
Descomposición de series temporales . . . 22
2.1 Frecuencia de muestreo . . . 23
Frecuencia de muestreo . . . 23
Series temporales de alta frecuencia . . . 23
2.2 Modelos estructurales vs. modelos ARIMA . . . 24
Modelos estructurales . . . 24
Modelos estructurales vs. ARIMA . . . 25

Resumen y consulta rápida 26
Cómo detectar y eliminar cada componente . . . 26
ACF y PACF: identificación de modelos . . . 26
Glosario de definiciones . . . 27
Observaciones sobre las diapositivas . . . 28

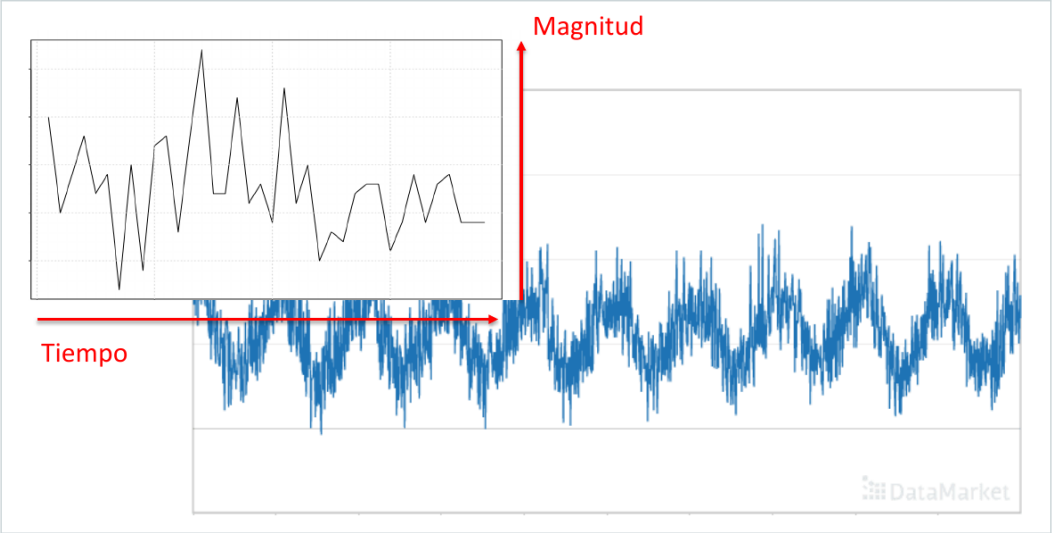
1 Componentes de las series temporales

Repaso

¿Qué es una serie temporal?

DEFINICIÓN · SERIE TEMPORAL

Una **serie temporal** es, por definición, un conjunto de datos ordenados en el tiempo.

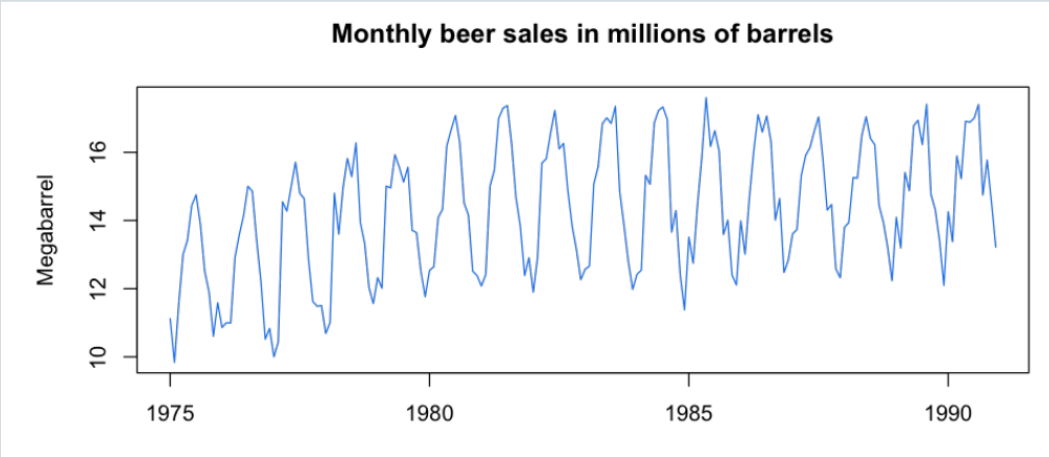


*Ejemplos de series temporales: en el eje vertical se representa la **magnitud** y en el eje horizontal el **tiempo**.*

Componentes de las series temporales

Los componentes que se estudian en las series temporales son:

- **Autocorrelación**
- **Tendencia**
- **Estacionalidad**
- **Estacionariedad**
- **Puntos de impacto**
- **Ruido o residuo**



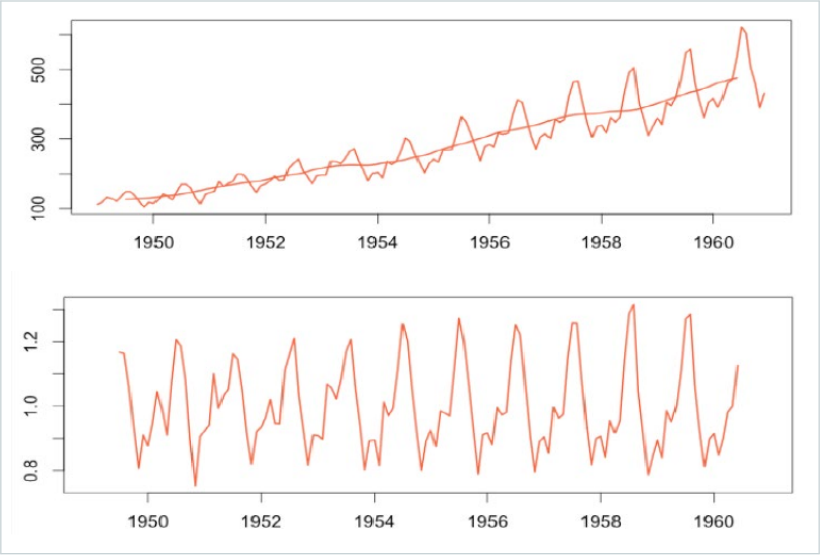
Ejemplo: Monthly beer sales in millions of barrels (ventas mensuales de cerveza en millones de barriles, 1975–1990). Se aprecia a simple vista una fuerte estacionalidad.

A continuación se desarrolla cada componente en el orden de las diapositivas: tendencia (1.1), estacionalidad (1.2), residuo y puntos de impacto (1.3), autocorrelación (1.4) y estacionariedad (1.5).

1.1 Tendencia

DEFINICIÓN · TENDENCIA

Se define como **tendencia** de una serie temporal a su variación a largo plazo, es decir, recoge el movimiento regular de la serie.



Arriba: serie con su tendencia superpuesta (1949–1960). Abajo: la serie una vez eliminada la tendencia.

Modelos de tendencia

La forma más sencilla de modelar la tendencia de una variable es a través de **regresiones con respecto a la variable temporal**.

- **Tendencia lineal**

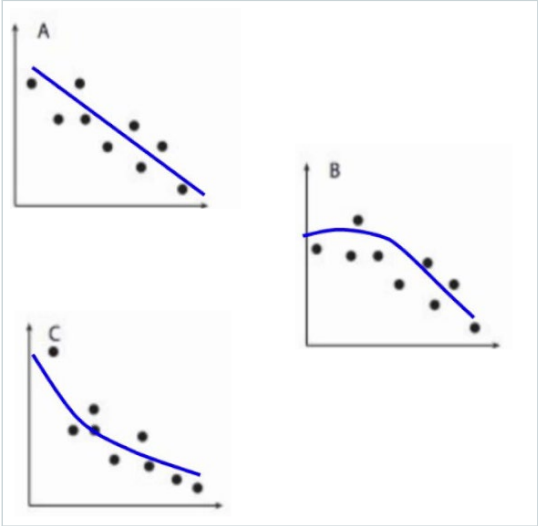
$$y_t = \beta_0 + \beta_1 t$$

- **Tendencia cuadrática**

$$y_t = \beta_0 + \beta_1 t + \beta_2 t^2$$

- **Tendencia exponencial**

$$y_t = e^{\beta_0 + \beta_1 t}$$



Ajustes sobre nubes de puntos: lineal (A), cuadrático (B) y exponencial (C).

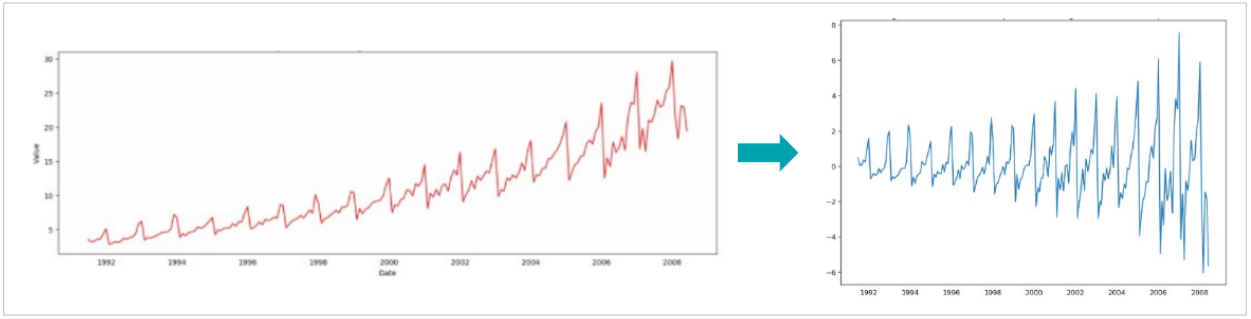
Eliminación de la tendencia

Existen varios métodos para eliminar la tendencia:

- Cuando tenemos una **tendencia lineal**, ésta se puede eliminar **diferenciando** la propia serie temporal:

$$S^*(t) = S(t) - S(t-1)$$

- Eliminar la **media móvil** de la serie temporal. Cuando hay una tendencia en la serie, la media móvil varía a lo largo de la serie temporal y tiene la forma de su tendencia.
- Eliminación de la media móvil mediante el **Filtro de *Baxter-King***. Es un filtro lineal que elimina tanto la tendencia como las oscilaciones de alta frecuencia (ruido), quedándose únicamente con las oscilaciones de frecuencia intermedia.
- Eliminar la **componente cíclica** mediante el **Filtro de *Hodrick-Prescott***. Este filtro es un método de suavizado de la serie temporal de la que se obtiene la tendencia de la serie.
- Utilizando la librería *seasonal_decompose* de ***Statsmodel***.



Serie original (izquierda) y serie tras eliminar la tendencia (derecha).

PRÁCTICA EN CLASE

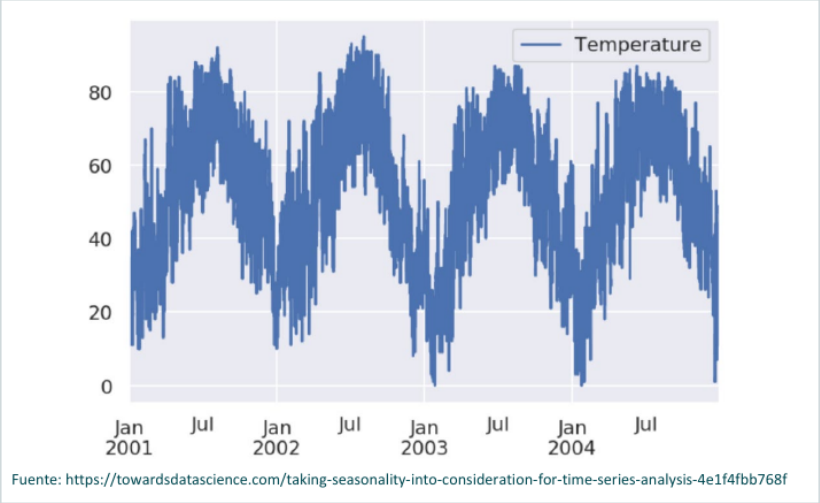
Ejemplo: Detrending — la profesora intercala aquí un ejercicio/ejemplo práctico; en las diapositivas solo figura el título.

1.2 Estacionalidad

DEFINICIÓN · SERIE ESTACIONAL

Se dice que una serie temporal es **estacional**, cuando tiene una variación periódica a lo largo del tiempo, y esta variación tiene una periodicidad menor o igual al año (trimestral, mensual, semanal...).

La estacionalidad es una componente muy relevante para la predicción de series temporales.



Temperatura entre enero de 2001 y finales de 2004: el patrón se repite cada año.
Fuente: https://towardsdatascience.com/taking-seasonality-into-consideration-for-time-series-analysis-4e1f4fbb768f

> *«la estacionalidad es el movimiento intra-anual sistemático, aunque no necesariamente regular, causado, directamente, por los cambios en el clima, el calendario y la temporización de las decisiones, o, indirectamente, a través de las decisiones de producción y consumo hechas por los agentes de la economía. Estas decisiones son influidas por las dotaciones, las expectativas y las preferencias de los agentes, y por las técnicas de producción disponibles en la economía».*
>
> — Hylleberg (1992:4)

Tipos de estacionalidad

- **Estacionalidad determinista**: cuando la estacionalidad viene dada por fluctuaciones periódicas estables, que no cambian en el tiempo.
- **Estacionalidad no exógena**: cuando la componente estacional varía en el tiempo.

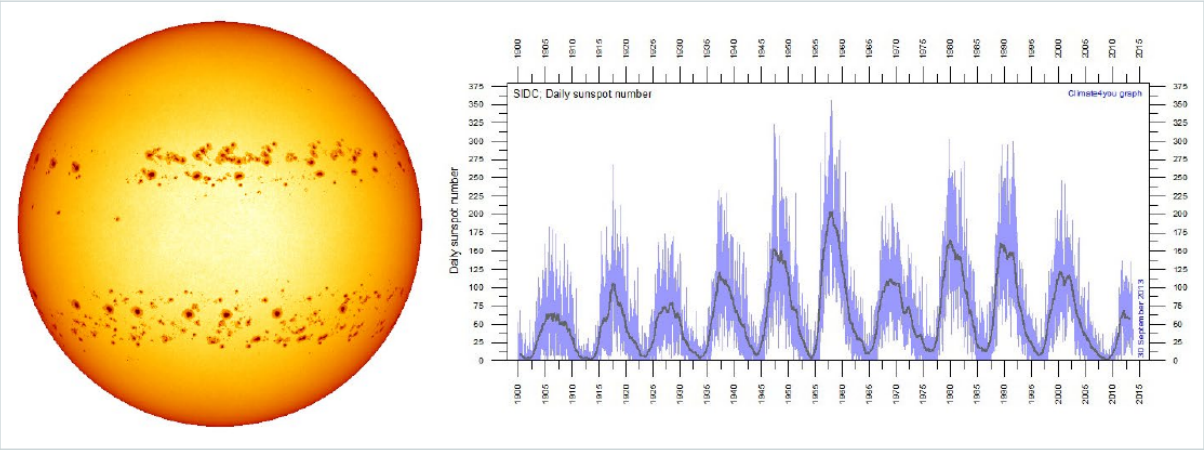
Causas de la estacionalidad

- **Calendario laboral**: variación en función del día de la semana, mes del año o franja horaria dentro del día.
- **Clima**: variación de la serie temporal en función de la estación del año.
  - Exportación de alimentos de países cálidos en temporadas de frío en países nórdicos.
  - Demanda hostelera de zonas cálidas durante el otoño o invierno.
- **Temporalidad de actividades**:
  - Pagas extras
  - Vacaciones
- **Expectativas**: estacionalidad debida a las expectativas del mercado.
  - Incremento de compras en navidades

Componente cíclica

DEFINICIÓN · COMPONENTE CÍCLICA

Cuando una serie presenta comportamientos recurrentes o periódicos con un periodo **superior al año**, entonces hablaremos de la **componente cíclica**, y no de la componente estacional.



Actividad solar: número diario de manchas solares (SIDC), 1900–2015. Comportamiento recurrente con un periodo muy superior al año.

Fuente: https://www.cosmos.esa.int/web/cesar/rotation-period-and-sunspot-activity

Comprobación de la estacionalidad

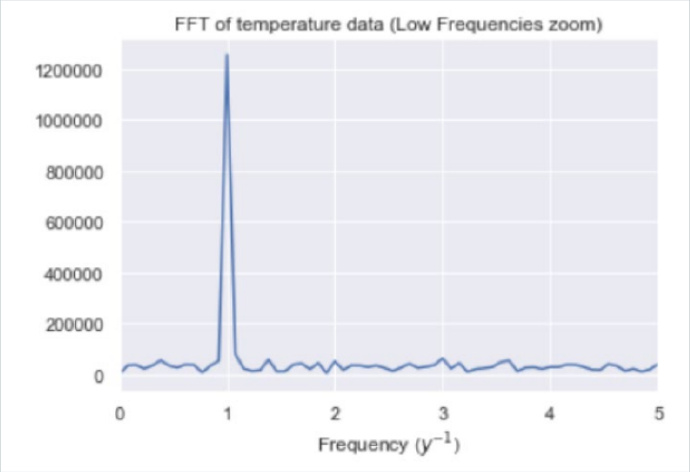
- **A ojo.**
- **Función de autocorrelación**: cuando calculamos la autocorrelación de una serie que presenta estacionalidad, observamos picos significativos para desfases repetidos en las ventanas estacionales.
- **Media móvil**: la media móvil nos ofrece una versión suavizada de la componente estacional.
- **Obtención de frecuencias mediante la Transformada de Fourier.** La transformada de Fourier nos permite descomponer una serie temporal en sus frecuencias de oscilación.

Transformada de Fourier

DEFINICIÓN · TRANSFORMADA DE FOURIER

La Transformada de Fourier representa una función temporal en el **espacio de frecuencias**. Esto nos permite obtener el **espectro de frecuencias** de una función.

$$F(\omega) = \int_{-\infty}^{\infty} F(t)\, e^{-i\omega t}\, dt \quad // \quad F(f) = \int_{-\infty}^{\infty} F(t)\, e^{-i2\pi F(t)}\, dt$$



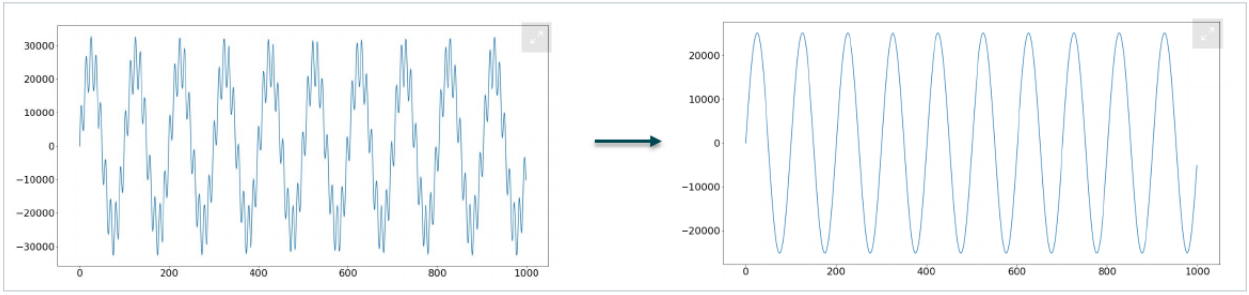
FFT de datos de temperatura (zoom a bajas frecuencias): el pico en la frecuencia de 1 año^{-1} revela la estacionalidad anual.

Uso de la transformada para eliminar ruido

La Transformada de Fourier se utiliza comúnmente para **eliminar ruido** de series temporales.

- Realizamos la transformada de Fourier a la serie.
- Quitamos las altas frecuencias de la representación de la serie en el espacio de frecuencias mediante una máscara.
- Realizamos la anti-transformada o transformada inversa de Fourier.

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega)\, e^{i\omega t}\, d\omega$$



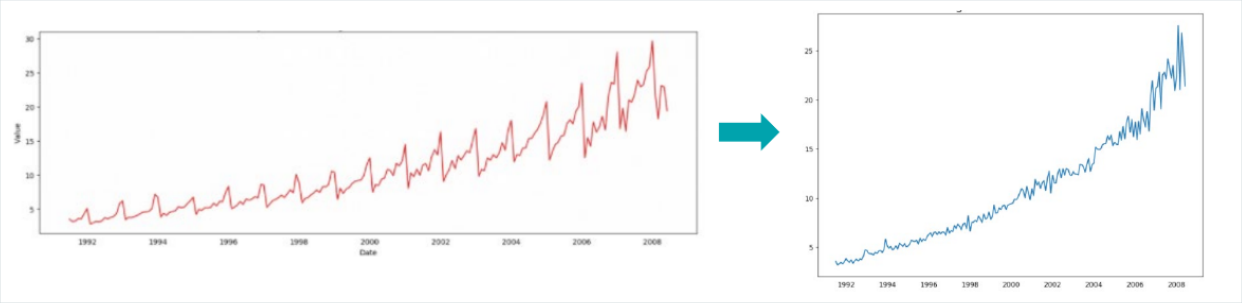
Serie con ruido (izquierda) y serie tras filtrar las altas frecuencias y aplicar la transformada inversa (derecha).
Fuente: https://realpython.com/python-scipy-fft/

Eliminación de la estacionalidad

- Eliminando la **media móvil** con intervalo igual al periodo.
- También puede eliminarse la estacionalidad **diferenciando** la serie temporal con respecto al mismo momento del periodo anterior:

$$S^*(t) = S(t) - S(t - S)$$

  donde *S* es el periodo estacional.
- Mediante el uso de la librería ***seasonal_decompose*** de *Statsmodel*.



Serie original (izquierda) y serie sin estacionalidad (derecha).

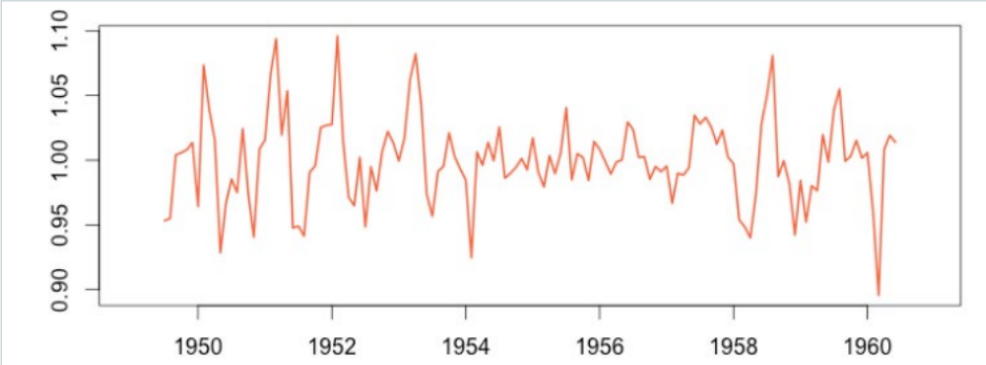
PRÁCTICA EN CLASE

Ejemplo: Estacionalidad — la profesora intercala aquí un ejercicio/ejemplo práctico; en las diapositivas solo figura el título.

1.3 Residuo

Ruido o residuo

- El **ruido o residuo** es una componente aleatoria de las series temporales.
- Puede deberse a errores en las medidas y dificultan un ajuste óptimo de la serie temporal. Pero según qué series temporales estemos tratando no es más que la componente de la serie que no se puede modelar y, por lo tanto, explicar correctamente.



Ejemplo de componente residual de una serie (1950–1960).

Puntos de impacto

- Algunas series temporales tienen **picos discretos** que no ocurren con periodicidad.
- Los **puntos de impacto** se deben a fenómenos puntuales (fenómeno meteorológico adverso, ataque terrorista, accidente, etc.) que no son previsibles.
- A estos picos discretos se les denomina **efectos de impacto**.



Serie con Impacts (impactos), Seasons (estacionalidad) y Trend (tendencia).

1.4 Autocorrelación

Autocorrelación

DEFINICIÓN · AUTOCORRELACIÓN
La **autocorrelación** representa el grado de similitud entre una serie temporal y su versión desfasada en un cierto intervalo temporal. Dicho de otro modo, la autocorrelación mide la **relación entre los valores actuales de una variable y sus valores pasados**.

- Si la autocorrelación es +1 o −1, estaremos frente a una **correlación perfecta**.
- La autocorrelación se utiliza para:
  - medir la influencia de los valores pasados en los presentes.
  - encontrar patrones periódicos en la serie ocultos por el ruido.
- Viene representada por la siguiente ecuación:

$$R_{xx}(\tau) = \frac{\sum_{t=1}^{n-\tau}(x_t - \bar{x})(x_{t+\tau} - \bar{x})}{\sum_{t=1}^{n}(x_t - \bar{x})^2} = \frac{\operatorname{cov}(x_t, x_{t+\tau})}{\operatorname{var}(x_t)}$$

donde τ es el desfase temporal, $\bar{x}$ es la media de la serie y x_t el valor de la serie temporal en el instante t.

Cálculo aproximado con media cero

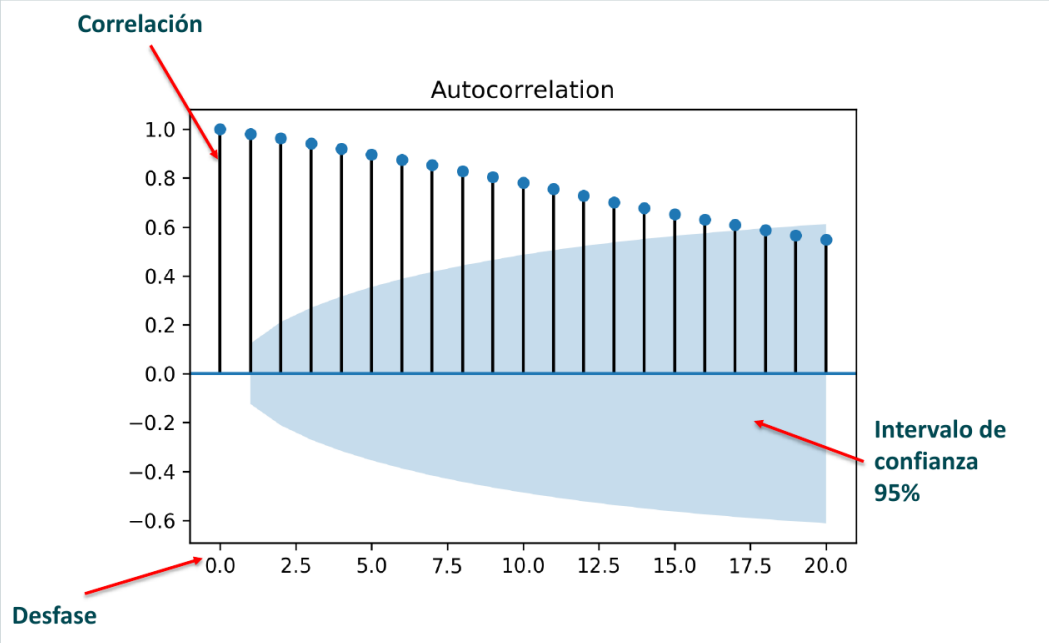
Asumamos que la media de la serie es cero ($\bar{x} = 0$), tendremos la siguiente aproximación (serie de cuatro valores x_0, x_1, x_2, x_3; se desplaza la serie τ posiciones y se suman los productos de los valores que quedan superpuestos):

Desfase	Aproximación
$\tau = 0$	$R_{xx}(0) \approx x_0x_0 + x_1x_1 + x_2x_2 + x_3x_3$
$\tau = 1$	$R_{xx}(1) \approx x_1x_0 + x_2x_1 + x_3x_2$
$\tau = 2$	$R_{xx}(2) \approx x_2x_0 + x_3x_1$
$\tau = 3$	$R_{xx}(3) \approx x_3x_0$

Función de autocorrelación (ACF)

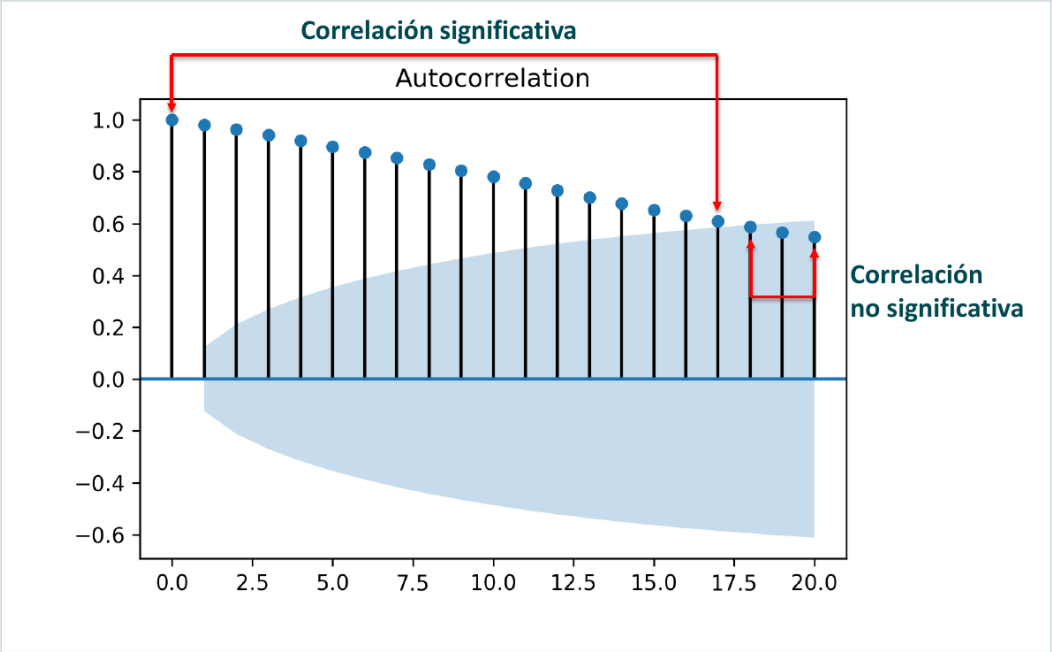
DEFINICIÓN · ACF

La **función de autocorrelación** (ACF por sus siglas en inglés) es una representación de los coeficientes de autocorrelación calculados teniendo en cuenta un número de desfases diferentes.

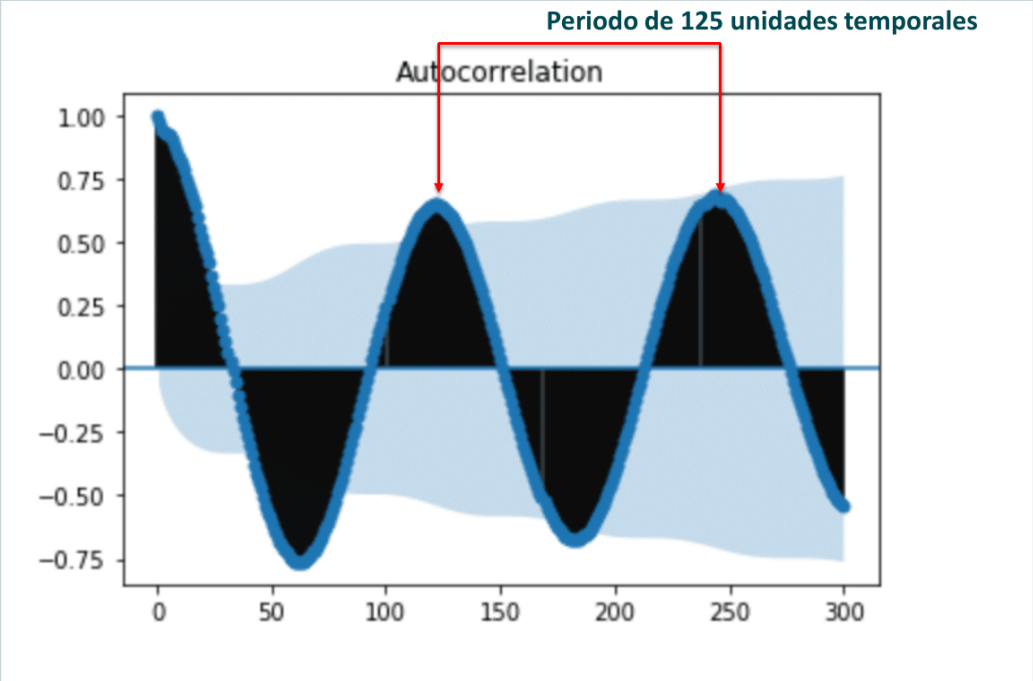


Elementos de un gráfico de ACF: correlación, desfase e intervalo de confianza del 95 %.

- **Correlación**: valor del coeficiente de autocorrelación (eje vertical).
- **Desfase**: intervalo temporal considerado (eje horizontal).
- **Intervalo de confianza 95 %**: zona sombreada.
- **Correlación significativa**: la que se sale del intervalo de confianza. **Correlación no significativa**: la que queda dentro (en el ejemplo, los últimos desfases).



Correlaciones significativas (desfases 0 a 17) y no significativas (desfases 18 a 20).

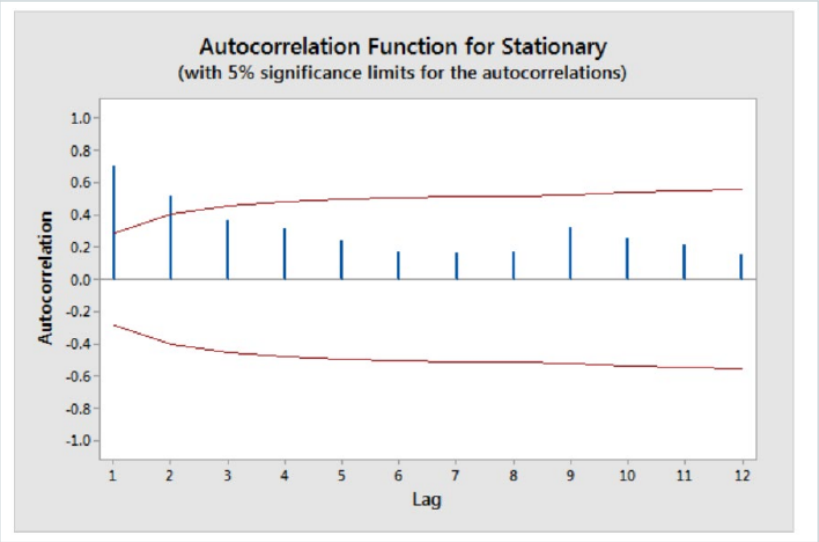


Periodo de 125 unidades temporales: los máximos de la ACF se repiten cada 125 desfases, lo que revela un patrón periódico en la serie.

ACF según el tipo de serie

ACF: series estacionarias

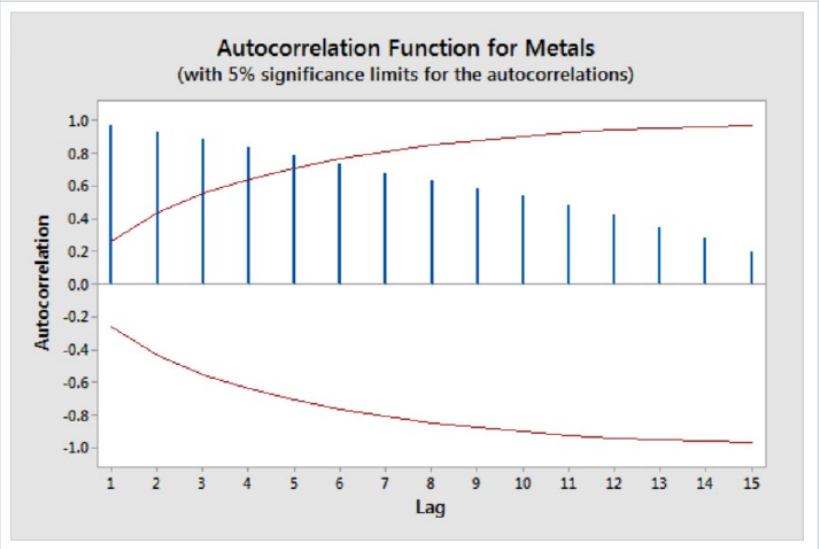
- Una serie estacionaria, que no tiene tendencia ni estacionalidad, y que, además, tiene una varianza constante, muestra una función de autocorrelación que **decae rápidamente a cero**.
- Una serie no estacionaria, por el contrario, muestra una función de autocorrelación que **decae más lentamente**.



ACF de una serie estacionaria (con límites de significación del 5 %).

ACF: series con tendencia

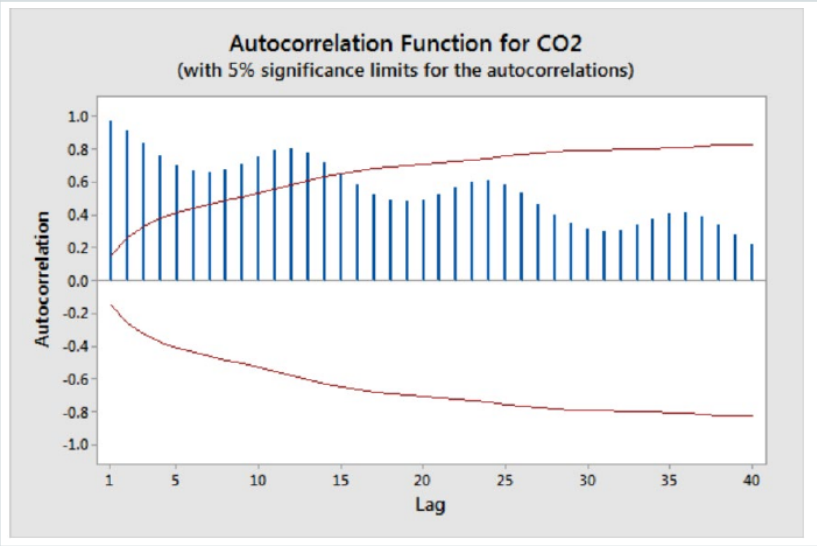
Cuando una serie temporal presenta una **tendencia**, la función de autocorrelación muestra una correlación mucho más fuerte en desfases cortos, porque los valores de la serie en puntos (instantes temporales) más cercanos, tienen valores más similares. La correlación disminuye a medida que el desfase temporal aumenta.



ACF de una serie con tendencia (Metals).

ACF: series estacionales

- Cuando una serie temporal presenta **estacionalidad**, la función de autocorrelación muestra un aumento en la correlación en los desfases proporcionales al periodo estacional.
- Si además, la serie temporal presenta tendencia, la función de autocorrelación muestra ambos efectos.

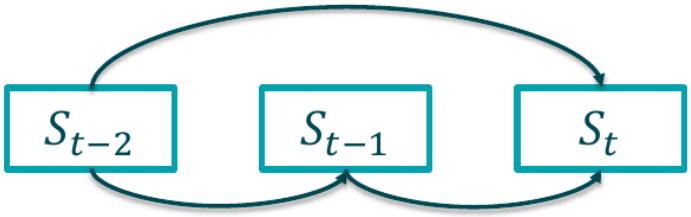


ACF de una serie con estacionalidad y tendencia (CO2).

Autocorrelación parcial (PACF)

DEFINICIÓN · AUTOCORRELACIÓN PARCIAL

La **autocorrelación parcial** de un desfase *k*, elimina todas las influencias indirectas de los desfases temporales menores a *k*.



S_{t-2} influye en S_t directamente y, de forma indirecta, a través de S_{t-1}.

	Correlación entre S_t y S_{t-2}	Influencias que recoge
ACF	CORR(S_t, S_{t-2})	Directa: $S_{t-2} \rightarrow S_t$ Indirecta: $S_{t-2} \rightarrow S_{t-1} \rightarrow S_t$
PACF	CORR(S_t, S_{t-2})	Directa: $S_{t-2} \rightarrow S_t$

En muchas ocasiones, la autocorrelación entre *t* y *t*−2 es muy buena, pero esta alta autocorrelación se debe al **término indirecto**, es decir, a la influencia de *t*−1 en *t*.

$$S_t = \rho_{21} S_{t-1} + \rho_{22} S_{t-2} + \varepsilon_t$$

Aquí ρ_{22} es el **coeficiente de influencia directa** de S_{t-2} sobre S_t.

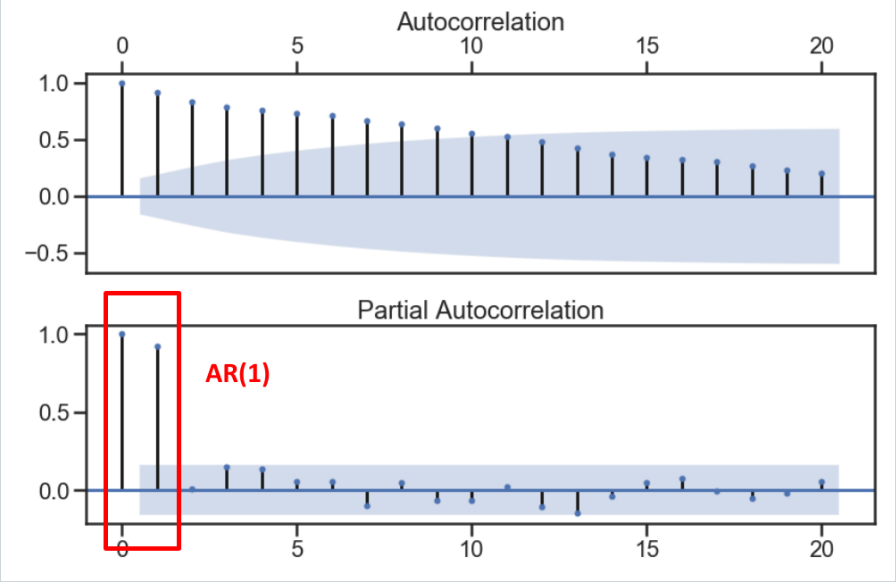
Selección del modelo

Normalmente se utilizará la **ACF** para saber si un modelo autorregresivo es adecuado para modelar la serie temporal, y el **PACF** nos ayudará con la selección de los parámetros del modelo.

Modelo	ACF	PACF
AR(p)	Variación geométrica	Significativo hasta *p*
MA(q)	Significativo hasta *q*	Variación geométrica
ARMA	Significativo hasta *q*	Significativo hasta *p*

Selección del modelo: AR(p)

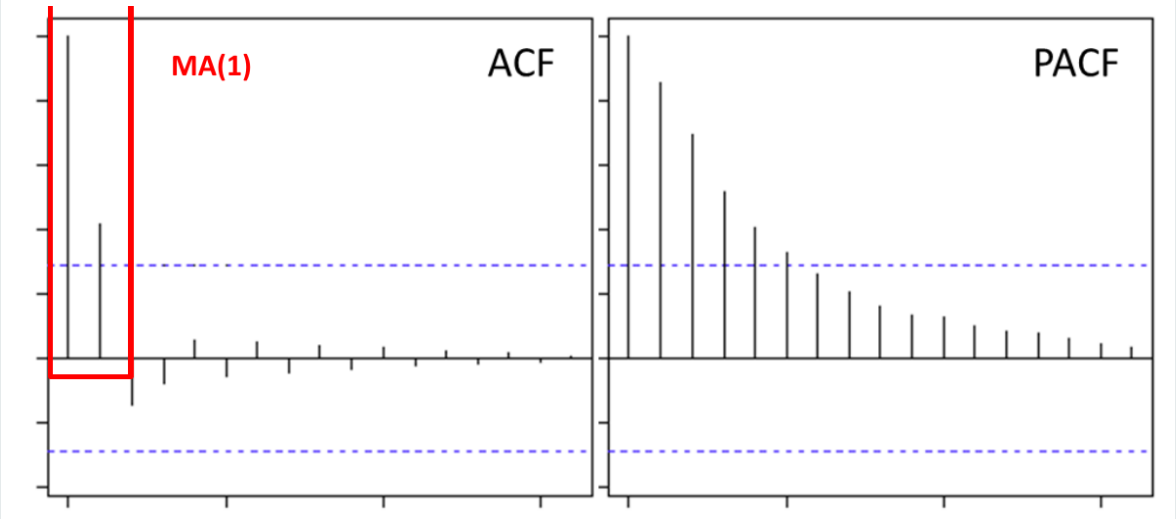
El orden *p* lo estimamos del **número de desfases significativos del PACF**.



*ACF (arriba) y PACF (abajo): solo el primer desfase del PACF es significativo → **AR(1)**.*

Selección del modelo: MA(q)

El orden *q* lo estimamos del **número de desfases significativos del ACF**.

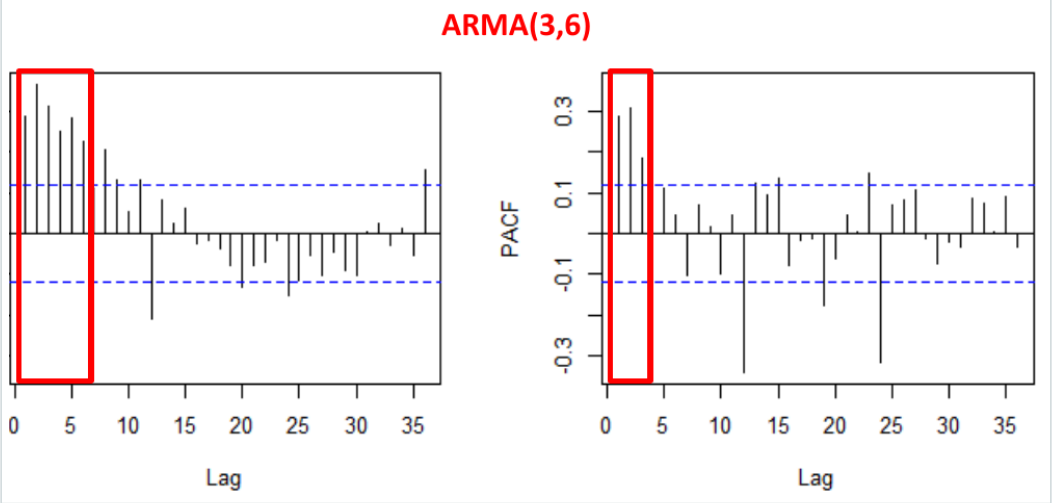


*ACF (izquierda) y PACF (derecha): solo el primer desfase del ACF es significativo → **MA(1)**.*

Fuente: http://nmmarcelnv.pythonanywhere.com/static/epilearn/img/acf_pacf_plot.png

Selección del modelo: ARMA(p,q)

En un ARMA se miran ambas funciones: el ACF es significativo hasta el desfase 6 (**MA(6)**) y el PACF hasta el desfase 3 (**AR(3)**), luego el modelo candidato es **ARMA(3,6)**.



*ACF (izquierda) y PACF (derecha) → **ARMA(3,6)**.*

Para afinar los órdenes *p* y *q*:

- Aplicar el **Criterio de Información de Akaike (AIC)** o el **Criterio de Información Bayesiano (BIC)**. Estas son métricas que evalúan la calidad de los modelos. Nos basamos en estas métricas para obtener los valores de *p* y *q* que nos den los órdenes óptimos (valores mínimos de las métricas).
- Utilizar el **Test estadístico de Ljung-Box** para determinar si los órdenes *p* y *q* obtenidos ajustan bien nuestro modelo. Si se cumple la hipótesis nula entonces tendremos un buen ajuste.
- La librería ***auto-arima*** tiene la implementación de las dos partes necesarias para obtener un buen ajuste.

1.5 Estacionariedad

Definición de estacionariedad

DEFINICIÓN · SERIE ESTACIONARIA

Se define como **serie estacionaria**, aquella serie temporal cuyas propiedades estadísticas no varían con el tiempo. Dicho de otro modo, en las series temporales estacionarias, la **forma en que varía** la serie no cambia a lo largo del tiempo.

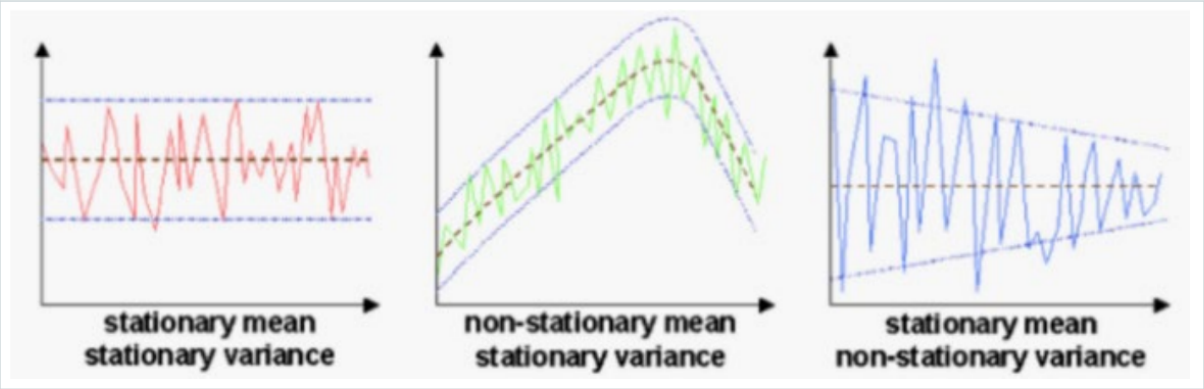
En términos estadísticos, esto se traduce en:

Media constante	$\mu(t) = E(x_t) = \mu$
Varianza constante	$\sigma^2(t) = E[(x_t - \mu)^2] = \sigma^2$
Autocovarianza constante	$\gamma_k(t) = E[(x_t - \mu)(x_{t+k} - \mu)] = \gamma_k$

Si una serie temporal tiene media, varianza y covarianza constantes en el tiempo, decimos que es **estrictamente estacionaria**.

En este caso, la serie no tendrá tendencia, estacionalidad, ni puntos de impacto, es decir, **carecerá de estructura**.

- Si una serie temporal tiene una media constante a lo largo del tiempo, decimos que es **estacionaria con respecto a la media**.
- Si tiene varianza constante en el tiempo, decimos que es **estacionaria en varianza**.

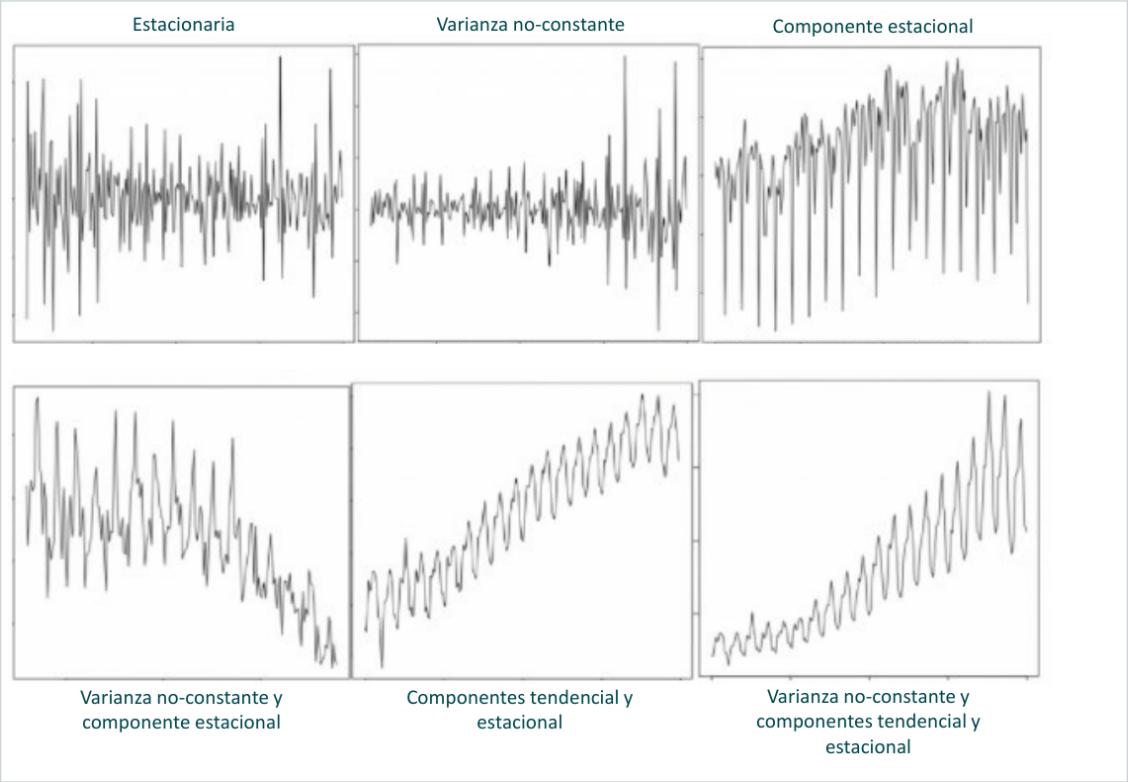


Media y varianza estacionarias (izquierda); media no estacionaria y varianza estacionaria (centro); media estacionaria y varianza no estacionaria (derecha).

Fuente: https://towardsdatascience.com/stationarity-in-time-series-analysis-90c94f27322

Matices en la definición de estacionariedad

- **Estacionariedad estricta**: todos los estadísticos de la serie temporal se mantienen constantes en el tiempo.
- **Estacionariedad en media o de primer orden**: estas series mantienen una media constante en el tiempo.
- **Estacionariedad débil o de segundo orden**: tanto la media como la varianza se mantienen constantes en el tiempo. Es estacionario en autocovarianza.
- **Estacionariedad tendencial**: son series que contienen una tendencia determinista de forma que, al eliminarla, la serie residual es estacionaria.
- **Estacionariedad diferencial**: estas series contienen una tendencia no determinista (aleatoria) y por lo tanto necesitan al menos una diferenciación para convertirse en estacionarias.



Series con distintas combinaciones: estacionaria; varianza no constante; componente estacional; varianza no constante y componente estacional; componentes tendencial y estacional; y varianza no constante con componentes tendencial y estacional.

Conversión de una serie en estacionaria

Aplicando una transformación adecuada, se puede convertir casi cualquier serie temporal en una estacionaria. Cada una de las transformaciones nos dará un resultado diferente:

- **Diferenciando la serie** (una o varias veces)
  - Eliminamos tendencia y estacionalidad
- Calculando el **logaritmo** de la serie
  - Eliminamos la varianza no constante
- Calculando la **raíz de orden n** de la serie
  - Eliminamos el polinomio de orden *n* que puede ajustar la serie
- Combinación de las anteriores

Comprobar estacionariedad

- **Comprobando los estadísticos**:

  Dividimos la serie temporal en dos o tres partes y comprobamos que los estadísticos se mantienen constantes.
- **Unit Root Tests**: test estadísticos que determinan de forma cuantitativa si una serie es estacionaria.

Unit roots / raíces unitarias

- Si tenemos una serie con **raíz unitaria** entonces **no es estacionaria**.
- Una serie AR(1):

$$a_t = \alpha a_{t-1} + \varepsilon_t$$

tiene raíz unitaria cuando $\alpha = 1$. Veamos la demostración:

$$a_t = \alpha a_{t-1} + \varepsilon_t = \alpha^t a_0 + \sum_{k=0}^{t-1} \alpha^k \varepsilon_{t-k}$$

Para comprobar la estacionariedad calculamos el valor esperado de la serie (media) y la varianza:

$$E(a_t) = \alpha^t a_0$$
$$\text{var}(a_t) = \sigma^2(\alpha^0 + \alpha^2 + \alpha^4 + \cdots + \alpha^{t-1})$$

Analizamos los tres casos posibles:

- **Valor unitario** ($\alpha = 1$):

$$E(a_t) = a_0 \qquad \text{var}(a_t) = \sigma^2 t \ \rightarrow \ \text{varianza no constante}$$

  Bajo estas condiciones, la serie **no será estacionaria**.

- **α mayor que uno en valor absoluto**:

$$E(a_t) \rightarrow \pm\infty$$

  Por lo tanto, no es constante y **no será estacionaria**.

- **α menor que 1 en valor absoluto**:

$$E(a_t) \rightarrow 0 \qquad \text{var}(a_t) \rightarrow \frac{\sigma^2}{1-\alpha^2}$$

  donde σ^2 es la varianza del residuo de la serie que se asume constante, y por lo tanto la serie **será estacionaria** en este caso.

Unit Root Tests

- **Augmented Dickey Fuller test (ADF Test)**: **hipótesis nula para raíz unitaria (serie no estacionaria)**. Esto es, si el p-valor es **menor** que el nivel de significación (0,05), entonces se cumple la **hipótesis alternativa** y, por lo tanto, tendremos una **serie estacionaria**. Además, la **estadística ADF tiene que ser mayor** a los valores críticos.
- **Kwiatkowski-Phillips-Schmidt-Shin (KPSS test)**: comprueba la **estacionariedad tendencial** (en torno a una tendencia). **Hipótesis nula para serie estacionaria**. Es decir, si el p-valor es **mayor** que el nivel de significación (0,05), entonces se cumple la **hipótesis nula** y, por lo tanto, tendremos una **serie estacionaria**. Además, la estadística del test **tiene que ser menor** a los valores críticos. Por defecto aplica la hipótesis sobre la media de la serie. Para aplicarlo sobre la serie con tendencia hay que especificarlo en las opciones.

Test	Hipótesis nula (H_0)	Serie estacionaria si...	Estadística vs. valores críticos
ADF	Raíz unitaria (serie no estacionaria)	p-valor < 0,05 (se cumple la hipótesis alternativa)	ADF mayor que los valores críticos
KPSS	La serie es estacionaria	p-valor > 0,05 (se cumple H_0)	Estadística menor que los valores críticos

Combinando los resultados de ambos test:

Test ADF	Test KPSS	Conclusión
No estacionaria	No estacionaria	La serie **NO es ESTACIONARIA**.
Estacionaria	Estacionaria	La serie **SÍ es ESTACIONARIA de primer orden**.
No estacionaria	Estacionaria	La serie es **ESTACIONARIA EN TENDENCIA**.
Estacionaria	No estacionaria	La serie es **ESTACIONARIA EN DIFERENCIACIÓN**.

PRÁCTICA EN CLASE

Ejemplo: Estacionariedad — la profesora intercala aquí un ejercicio/ejemplo práctico; en las diapositivas solo figura el título.

Heterocedasticidad

- Si tenemos una serie temporal no-estacionaria, muy probablemente nos encontraremos con una varianza que crece de forma sistemática siguiendo una tendencia determinista y/o con la estacionalidad. En este caso diremos que la regresión presenta **heterocedasticidad** (varianza cambiante a lo largo de la serie de forma regular).
- En finanzas, es habitual encontrar que periodos de alta volatilidad vienen seguidos de periodos de mayor volatilidad. En este caso, la serie temporal presenta **heterocedasticidad condicional**, es decir, la volatilidad de la serie depende de los instantes inmediatamente anteriores.
- Cuando la serie presenta un cambio en la volatilidad que no se identifica con observaciones previas, diremos que la serie presenta **heterocedasticidad incondicional**.

Test de heterocedasticidad

- Los test de raíz unitaria **consideran que el residuo de la serie es estacionario**, por lo que comprueban únicamente si la serie es estacionaria en tendencia. Por lo tanto, para comprobar que la varianza de la serie es constante (**homocedasticidad**) necesitaremos hacer uso de test específicos.
- Los test de heterocedasticidad consideran como **hipótesis nula** que la **varianza** de los residuos se mantiene **constante**. Por lo tanto, si el **p-valor es menor que el valor de significancia** podremos rechazar la hipótesis nula y considerar que nuestra serie **presenta heterocedasticidad**. El valor de significancia es de 0,05.
- Existen implementaciones en Python de varios test, pero la mayoría se aplica sobre modelos regresivos. Pero existe un test fiable que se puede aplicar sobre series temporales, incluso en aquellas de alta frecuencia.

Test de Engle

- El test fue propuesto por **Robert Engle en 1982** (premio Nobel de Economía en 2003).
- Hipótesis del test:

$$u_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \cdots + \alpha_q u_{t-q}^2 + \varepsilon_t$$

Donde u_t son los residuos y ε_t es ruido blanco o un residuo homocedástico, representa las fluctuaciones aleatorias de la varianza que no siguen un patrón.

- **Hipótesis nula H_0**: no hay heterocedasticidad condicional.

$$\alpha_1 = \alpha_2 = \cdots = \alpha_q = 0$$

  Lo que implica **varianza constante**.

- **Hipótesis alternativa H_1**: al menos un $\alpha_i \neq 0$, indicando que la varianza depende de residuos pasados.

PRÁCTICA EN CLASE

Ejemplo: Heterocedasticidad — la profesora intercala aquí un ejercicio/ejemplo práctico; en las diapositivas solo figura el título.

PRÁCTICA EN CLASE

Ejercicio: Heterocedasticidad — la profesora intercala aquí un ejercicio/ejemplo práctico; en las diapositivas solo figura el título.

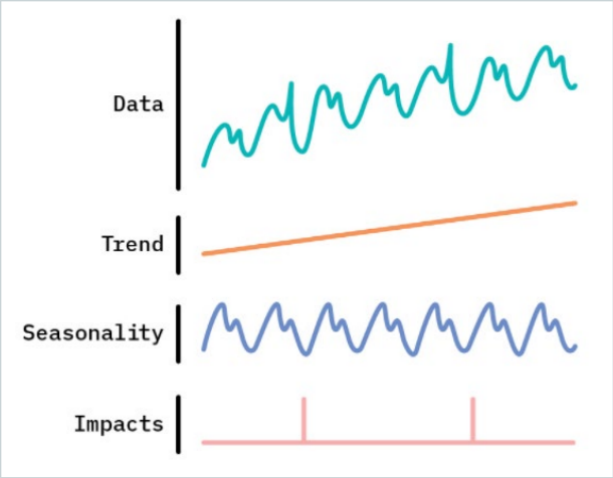
2 Series temporales estructurales

Series temporales estructurales y su descomposición

¿Qué es una serie temporal estructural?

DEFINICIÓN · SERIE TEMPORAL ESTRUCTURAL

Una **serie temporal estructural** es una serie temporal que tiene cierta estructura: **estacionalidad**, **tendencia** y **efectos de impacto**. Se representa la serie temporal como un **conjunto de componentes**.



Una serie (Data) representada como suma de tendencia (Trend), estacionalidad (Seasonality) e impactos (Impacts).

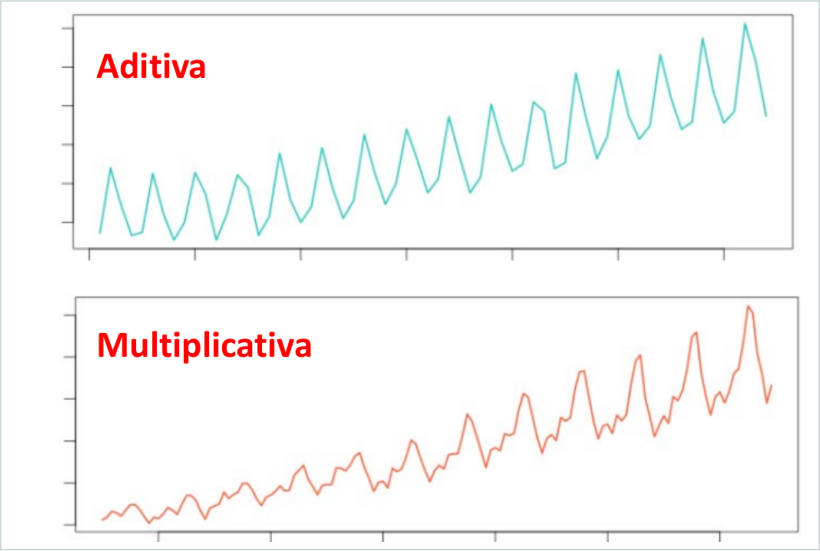
Descomposición de series temporales

Tipo de descomposición	Expresión
Descomposición aditiva	**y(t) = T + E + R + I**
Descomposición multiplicativa	**y(t) = T · E · R · I**

(La diapositiva no define las letras; se corresponden con los componentes vistos: **T** = tendencia, **E** = estacionalidad, **R** = ruido o residuo, **I** = efectos de impacto.)

¿CÓMO IDENTIFICAMOS EL TIPO DE DESCOMPOSICIÓN?

- Si la **amplitud de las fluctuaciones PRINCIPALES de la serie entorno a la media se mantiene constante** a lo largo de los ciclos → **Descomposición aditiva**.
- Si la **amplitud de las fluctuaciones PRINCIPALES de la serie entorno a la media varía de un ciclo a otro** → **Descomposición multiplicativa**.

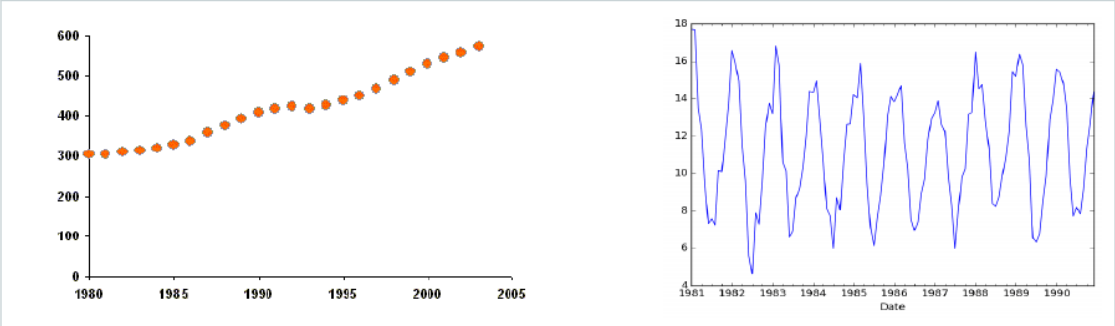


*Arriba: serie **aditiva** (amplitud constante). Abajo: serie **multiplicativa** (la amplitud de las oscilaciones crece con el nivel de la serie).*

2.1 Frecuencia de muestreo

Frecuencia de muestreo

- Para poder estudiar los modelos estructurales de series temporales necesitamos tener una frecuencia de medidas o eventos considerable.
- ¿Cuál es el mínimo de frecuencia de muestreo que necesitamos para poder analizar los componentes?



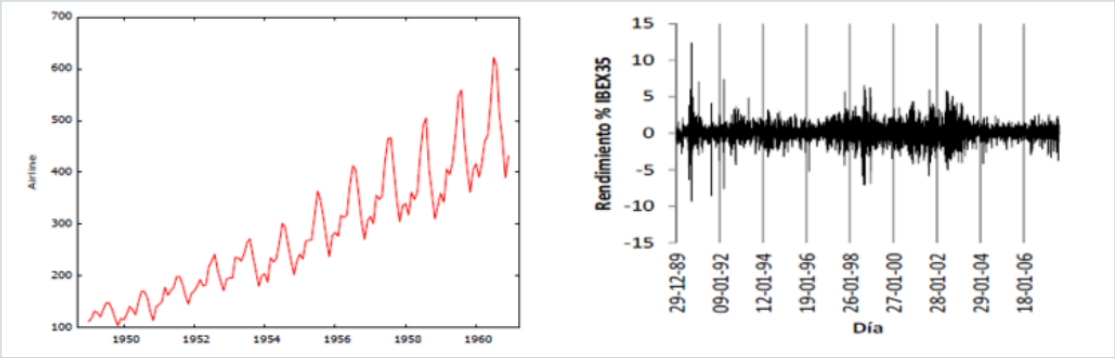
Izquierda: datos con una sola medida al año. Derecha: datos mensuales, donde ya se aprecia la estacionalidad.

RESPUESTA

- Se considera que la **frecuencia mínima** de muestreo para tener estacionalidad es de **1 medida por mes**.
- Aunque la frecuencia de muestreo puede ser mayor: semanal, horaria, minutal, etc.

Series temporales de alta frecuencia

- Se dice que una serie temporal es de **baja frecuencia**, cuando la frecuencia de muestreo **es mensual o inferior**.
- Se dice que una serie temporal es de **alta frecuencia**, cuando la frecuencia de muestreo **es superior a la frecuencia mensual** (semanal, diaria, horaria, etc.).



Izquierda: serie de baja frecuencia (Airline, mensual). Derecha: serie de alta frecuencia (rendimiento diario del IBEX35).

Las series temporales de alta frecuencia se encuentran principalmente en el ámbito de las **finanzas (series econométricas)**. Algunos de los problemas que nos podemos encontrar al analizar series temporales financieras son:

- La irregularidad en la frecuencia de muestreo.
- Fluctuaciones muy acentuadas en los datos.
- Patrones diarios.

PRÁCTICA EN CLASE

Ejercicio: Series estructurales — la profesora intercala aquí un ejercicio/ejemplo práctico; en las diapositivas solo figura el título.

2.2 Modelos estructurales vs. modelos ARIMA

Modelos estructurales

> *« … no son más que modelos de regresión en los que las variables explicativas son funciones del tiempo y los parámetros varían en el tiempo».*
>
> — Harvey (1989:10)

- Por lo general, cuando tratamos una serie temporal estructural, el comportamiento de **cada una de sus componentes puede describirse mediante un modelo de regresión** que tendrá como variables explicativas una tendencia determinista y propiedades de la estacionalidad.
- Cuando estas componentes no son estables, los **coeficientes de la regresión cambiarán con el tiempo**. Esto suele ocurrir en series temporales lo suficientemente largas para presentar inestabilidad.
- Los modelos estructurales nos permiten conocer en qué grado, **cada componente de la serie afecta** al comportamiento y evolución de ésta y, por lo tanto, nos permite constituir sobre qué elementos debemos apoyar las predicciones de la serie.

Modelos estructurales vs. ARIMA

- La principal ventaja de los modelos estructurales frente a los ARIMA para modelar series temporales estructurales es que los modelos estructurales nos permiten **obtener información sobre cada una de las componentes de la serie**, mientras que la aproximación ARIMA **trata de eliminar** las componentes tendencial y estacional, sin realizar un análisis previo de la estructura de la serie.
- Además, la eliminación de las componentes de la serie puede ser un inconveniente en sí mismo, ya que éstas pueden tener un **interés mayor que el resultado de la predicción**.
- Además, el **requerimiento de estacionariedad** en los modelos ARIMA implica la diferenciación de la serie (Box y Jenkins, 1976), pero no siempre es fácil decidir el orden de integración adecuado. De hecho, las funciones de autocorrelación utilizadas para identificar qué modelo debe ajustarse, son bastante imprecisas y no siempre permiten decantarse claramente por un único modelo.

Resumen y consulta rápida

Cómo detectar y eliminar cada componente

Componente	Cómo detectarla / comprobarla	Cómo eliminarla
Tendencia	Media móvil (varía a lo largo de la serie y tiene la forma de la tendencia). ACF con correlación mucho más fuerte en desfases cortos que disminuye al aumentar el desfase.	Diferenciar $S^*(t) = S(t) - S(t-1)$ (tendencia lineal); eliminar la media móvil; filtro de Baxter-King; filtro de Hodrick-Prescott; *seasonal_decompose* (Statsmodel).
Estacionalidad	A ojo; ACF (picos significativos en desfases repetidos / proporcionales al periodo); media móvil (versión suavizada); Transformada de Fourier (frecuencias de oscilación).	Eliminar la media móvil con intervalo igual al periodo; diferenciar $S^*(t) = S(t) - S(t-S)$; *seasonal_decompose*.
Ruido	Componente aleatoria; la parte de la serie que no se puede modelar.	Transformada de Fourier: máscara sobre las altas frecuencias y transformada inversa; filtro de Baxter-King (elimina oscilaciones de alta frecuencia).
Varianza no constante	Test de Engle (H_0: varianza constante; p-valor < 0,05 → heterocedasticidad).	Calcular el logaritmo de la serie.
No estacionariedad	Estadísticos por tramos; tests ADF y KPSS.	Diferenciar (una o varias veces), logaritmo, raíz de orden *n* o combinación de las anteriores.

ACF y PACF: identificación de modelos

Modelo	ACF	PACF	Ejemplo de las diapositivas
AR(p)	Variación geométrica	Significativo hasta *p*	PACF significativo en el desfase 1 → AR(1)
MA(q)	Significativo hasta *q*	Variación geométrica	ACF significativo en el desfase 1 → MA(1)
ARMA	Significativo hasta *q*	Significativo hasta *p*	ACF hasta 6 y PACF hasta 3 → ARMA(3,6)

Glosario de definiciones

Término	Definición
Serie temporal	Conjunto de datos ordenados en el tiempo.
Tendencia	Variación a largo plazo de una serie; recoge el movimiento regular de la serie.
Estacionalidad	Variación periódica a lo largo del tiempo con periodicidad menor o igual al año (trimestral, mensual, semanal...).
Componente cíclica	Comportamientos recurrentes o periódicos con un periodo superior al año.
Estacionalidad determinista	Fluctuaciones periódicas estables, que no cambian en el tiempo.
Ruido o residuo	Componente aleatoria de la serie; la parte que no se puede modelar y explicar correctamente.
Puntos / efectos de impacto	Picos discretos que no ocurren con periodicidad, debidos a fenómenos puntuales no previsibles.
Autocorrelación	Grado de similitud entre una serie y su versión desfasada; relación entre los valores actuales y pasados.
ACF	Representación de los coeficientes de autocorrelación para un número de desfases diferentes.
PACF	Autocorrelación de un desfase k que elimina las influencias indirectas de los desfases menores a k.
Serie estacionaria	Serie cuyas propiedades estadísticas (media, varianza, autocovarianza) no varían con el tiempo; carece de estructura.
Raíz unitaria	Propiedad de un AR(1) con $\alpha = 1$: la serie no es estacionaria.
Test ADF	H_0: raíz unitaria (no estacionaria). p-valor < 0,05 → estacionaria.
Test KPSS	H_0: serie estacionaria. p-valor > 0,05 → estacionaria.
Heterocedasticidad	Varianza cambiante a lo largo de la serie. Condicional: depende de los instantes anteriores; incondicional: no se identifica con observaciones previas.
Test de Engle	Propuesto por Robert Engle (1982). H_0: no hay heterocedasticidad condicional (varianza constante).
Serie temporal estructural	Serie con cierta estructura (estacionalidad, tendencia, efectos de impacto), representada como un conjunto de componentes.
Serie de baja / alta frecuencia	Baja: muestreo mensual o inferior. Alta: muestreo superior al mensual (semanal, diario, horario...).
Modelo estructural	Modelo de regresión en el que las variables explicativas son funciones del tiempo y los parámetros varían en el tiempo (Harvey, 1989).

Observaciones sobre las diapositivas

POSIBLES ERRATAS — CONVIENE CONFIRMARLAS CON LA PROFESORA

- **Estacionalidad «no exógena»** (diap. 13): por el contraste con la determinista, probablemente se refiere a la estacionalidad *estocástica* (la que cambia con el tiempo).
- **Transformada de Fourier** (diap. 17): en la segunda expresión aparece $e^{-i2\pi F(t)}$; la forma habitual es $e^{-i2\pi ft}$, con *f* la frecuencia.
- **Varianza del AR(1)** (diap. 56): el último término de la serie debería ser $\alpha^{2(t-1)}$ (es $\Sigma\ \alpha^{2k}$, con k de 0 a t−1); es coherente con el límite $\sigma^2/(1-\alpha^2)$ de la diap. 57.
- **Test ADF** (diap. 58): donde dice «hipótesis nula alternativa» debe entenderse hipótesis alternativa (H_1). Además, el estadístico ADF suele ser negativo y se rechaza H_0 cuando es *menor* (más negativo) que el valor crítico; «mayor» se entiende en valor absoluto.
- **Test KPSS** (diap. 58): donde dice «la estadística ADF tiene que ser menor…» se refiere a la estadística del test KPSS.
- **Descomposición** (diap. 68): las letras T, E, R, I no se definen en la diapositiva; aquí se han interpretado como tendencia, estacionalidad, residuo e impactos.